

Sistema de IA para Compliance Regulatorio

Propuesta de inversión para automatización del proceso de alertas AML — FinServ

1. EL PROBLEMA EN NÚMEROS

El equipo de 40 analistas resuelve aproximadamente 1.670 alertas por mes, dedicando en promedio 4,2 horas a cada una. El 68% resultan ser falsas alarmas, pero identificarlo requiere el mismo proceso de investigación que cualquier otra alerta: reunir documentos, revisar historial, llegar a una conclusión. El costo total supera los \$99.000 USD mensuales.

Costo mensual actual	Alertas / mes	Horas por alerta	Son falsos positivos
\$99.700	1.670	4,2 h	68%

Supuestos: 40 analistas × \$2.500/mes ÷ 176 h/mes = \$14,2/h · 1.670 alertas/mes = capacidad total del equipo a 4,2 h/alerta · se asume que el 100% del tiempo se dedica a evaluación de alertas.

2. LA SOLUCIÓN: UNA PLATAFORMA QUE CRECE POR ETAPAS

La solución no es un sistema que se instala y reemplaza el proceso existente. Es una plataforma que se construye en sprints de dos semanas, donde cada etapa entrega valor inmediato antes de que empiece la siguiente. La automatización completa llega al final, cuando ya existe evidencia operativa de que el sistema funciona correctamente. El riesgo regulatorio se posterga hasta que hay datos que lo respaldan.

Etapa	Quincena de desarrollo	Quincena siguiente
Buscador de documentos	Desarrollo de un motor de búsqueda semántica y por palabras clave de documentos regulatorios.	Los analistas tienen un buscador de normativa. Se reduce el tiempo de auditoría y se liberan analistas.
Buscador de artículos	Desarrollo de un motor de búsqueda superador, ahora a nivel de artículo. Los analistas liberados marcan la estructura de los documentos para una mejor indexación.	Los resultados de búsqueda son más relevantes. Se reduce el tiempo de auditoría y se liberan más analistas.
Referencias cruzadas	Detección de referencias cruzadas en corpus regulatorio con LLM. Los analistas liberados revisan las referencias. Desarrollo de navegación a documentos referidos en visualización de documentos.	Se pueden consultar documentos referidos y referentes. Se reduce el tiempo de auditoría y se liberan más analistas.
Agente investigador	Desarrollo de un agente investigador que reúne la información asociada a la alerta y la reglamentación aplicable. Los analistas liberados revisan la recolección automática de información.	El analista recibe un expediente ya completo para analizar y decidir. Se reduce el tiempo de auditoría y se liberan más analistas.
Agentes expertos	Desarrollo de un agente experto por país y uno por tema que analizan los casos y emiten una opinión calificada como contribución al análisis. Los analistas liberados juzgan y cuestionan las opiniones de los agentes expertos.	Los expedientes enriquecidos facilitan la decisión del analista. Se reduce el tiempo de auditoría.
Analizador de riesgo	Desarrollo de un agente experto que lea un expediente completo y produzca un score de riesgo, un nivel de confianza, y un paso a paso de razonamiento.	El trabajo de análisis está hecho y el analista sólo debe corregir si es necesario. Se reduce al máximo el tiempo de auditoría.

Etapa	Quincena de desarrollo	Quincena siguiente
Agente de decisión	<i>Desarrollo de un agente que toma la decisión final en casos en que hay confianza suficiente en el juicio automático.</i>	El sistema resuelve automáticamente un alto porcentaje de las alertas. Se reduce el tiempo promedio de auditoría al hacer que la auditoría humana sólo se aplique en una parte de los casos.

3. ROI PROYECTADO

El tiempo promedio por alerta bajará por dos vías. Durante los meses de desarrollo, el trabajo de los analistas irá recibiendo cada vez más asistencia —buscador de normas, expediente preparado, opiniones expertas, score de riesgo— de manera que su tiempo efectivo baje progresivamente hasta aproximadamente 2 horas por alerta. Cuando finalmente se active el agente de decisión, el 74% de las alertas se resolverá automáticamente: para ese 74% el tiempo humano es cero, y para el 26% restante es 2 horas. El promedio resultante es ~30 minutos.

Desarrollo (7 sprints distribuidos)	~\$80.000	Ahorro acumulado, meses 1–7	~\$296.000
Indexación inicial vía LLM (único)	~\$500	Ahorro meses 8–12 (×5 a \$87.300/mes)	~\$436.500
Transición de personal (único)	~\$30.000	Ahorro total año 1	~\$732.500
Infraestructura GCP (mensual)	\$130/mes	Costos totales año 1	~\$115.700
LLM en producción — modelo premium	\$200/mes	Retorno neto año 1	~\$617.000
Mantenimiento de infra (mensual)	\$100/mes	Break-even	Mes 2–3
Total costos fijos	~\$110.500		
Total costos recurrentes / mes	\$430/mes		

Mes
2–3

break-even real, antes de haber activado ningún agente autónomo. El ahorro de las dos primeras etapas —que son solo herramientas para analistas humanos— cubre los costos fijos del proyecto.

El ahorro acumulado en los meses 1–7 asume reducciones conservadoras de ~30 min/alerta por etapa. Los valores reales se medirán desde el día 1 y ajustarán el plan. El costo de desarrollo de \$80.000 se distribuye a lo largo de los 7 sprints, no como desembolso único al inicio.

4. EL RIESGO PRINCIPAL Y SU MITIGACIÓN

Riesgo regulatorio crítico

Las regulaciones de Colombia, México y Perú exigen que toda alerta relacionada con personas políticamente expuestas (PEPs) sea revisada por un analista humano, sin excepción. Un descarte automático de estas alertas constituye incumplimiento regulatorio independientemente del resultado. Las multas asociadas suelen superar el costo total de implementación del sistema.

La mitigación opera en dos niveles.

El primero es estructural: el agente de decisión llega en la quincena 7, después de cinco meses en los que todos los casos han pasado por analistas humanos. Para ese momento, el sistema habrá acumulado miles de decisiones humanas reales, incluyendo todas las que involucraron PEPs. El agente aprende de esos patrones: habrá observado que los casos de PEPs siempre son escalados, sin excepción, y ese patrón queda incorporado en su modelo de decisión.

El segundo es operativo: cuando el agente entra en producción, los analistas liberados siguen revisando el 100% de los descartes automáticos antes de que sean definitivos. La autonomía plena no se otorga de golpe; se amplía a medida que los datos de producción confirman que el agente no comete errores de escalación.

Nota para la evaluación: esta mitigación asume que el aprendizaje por patrones es suficiente para garantizar el comportamiento correcto en casos PEP. Esta suposición es discutida en detalle en el Challenge 05 del README, donde se analiza un escenario en que el agente falla precisamente en este punto y se propone una solución técnica más robusta.